

Iniciação Científica & Tecnológica

Universidade Presbiteriana Mackenzie



Iniciação Científica & Tecnológica

PREDIÇÃO DE PARÂMETROS CLIMÁTICOS COMO TEMPERATURA POR MEIO DO USO DE APRENDIZADO DE MÁQUINA

Daniel Borges Valentim (IC)

Orientador: **Prof. Júlio Cesar Ardito**

Apoio: **PIVIC Mackenzie**

XXII Jornada de Iniciação Científica · 2026

Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

INTRODUÇÃO

Prever a temperatura local ainda é um desafio

Modelos numéricos

Simulam a física da atmosfera, mas perdem precisão na escala local

Aprendizado de Máquina

Aprende padrões direto dos dados das estações de superfície

Dois cuidados

Variáveis muito correlacionadas e validação que “enxerga o futuro”

Por que isso importa

- Agricultura
- Recursos hídricos
- Prevenção de desastres
- Planejamento urbano

Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

INTRODUÇÃO

Pergunta de pesquisa e objetivos

Como diferentes algoritmos de aprendizado de máquina se comportam ao prever a temperatura horária em microclimas distintos — e qual é o real impacto do vazamento de dados na validação?

01

Mapear a estrutura do clima

Análise de Componentes Principais (PCA)

02

Comparar modelos

Regressão Linear (OLS) × Random Forest, Gradient Boosting e XGBoost

03

Testar a validação

K-Fold aleatório × Time Series Split cronológico

Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

METODOLOGIA

Dados reais do INMET em 4 microclimas de São Paulo

Fonte: INMET

Registros horários de 2025

Alvo: temperatura do ar (°C)

Mirante de Santana

CAPITAL

Ilha de calor urbana

Barueri

CONTINENTAL

Clima metropolitano mais estável

Interlagos

REPRESA

Influência da represa Guarapiranga

Bertioga

LITORAL

Brisa marítima e frentes frias

Pré-processamento: interpolação bidirecional (radiação e precipitação) e mediana (direção e velocidade do vento)

Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

METODOLOGIA

4 cenários incrementais de variáveis

	C1 Física limpa	C2 Física + histórico	C3 Física + tempo	C4 Caos total
Física instantânea (6) precipitação, pressão, radiação, umidade, direção e velocidade do vento	●	●	●	●
Histórico da hora anterior (5) pressão máx./mín., umidade máx./mín., rajada máxima	○	●	○	●
Marcadores temporais (2) hora do dia e mês do ano	○	○	●	●
Total de variáveis	**6**	**11**	**8**	**13**

Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

METODOLOGIA

Modelos comparados

ENSEMBLES DE ÁRVORES DE DECISÃO

OLS

Regressão linear múltipla: linha de base paramétrica

Random Forest

Bagging: árvores independentes, resultados agregados

Gradient Boosting

Boosting: árvores em sequência corrigem o erro anterior

XGBoost

Boosting com regularização L1/L2 contra overfitting

PCA
estrutura das variáveis

Fine-tuning
300 treinamentos por cenário

Métricas
R^2, MAE e RMSE

Universidade Presbiteriana Mackenzie

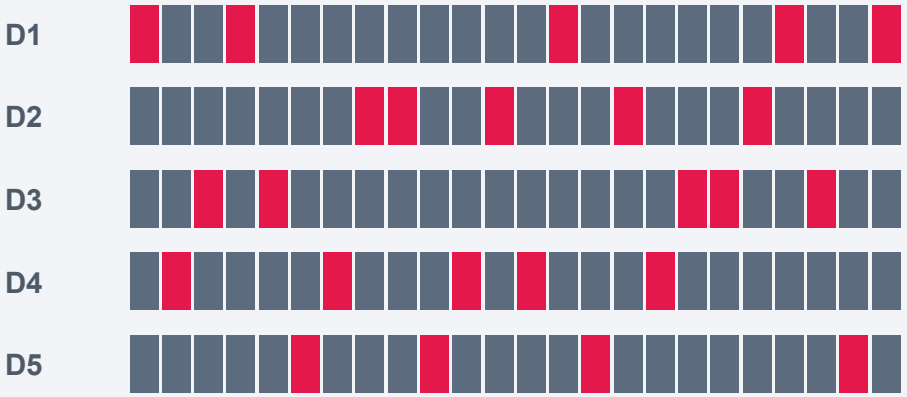
Iniciação Científica & Tecnológica

METODOLOGIA

Como validar um modelo em série temporal?

K-Fold aleatório

5 dobras com embaralhamento

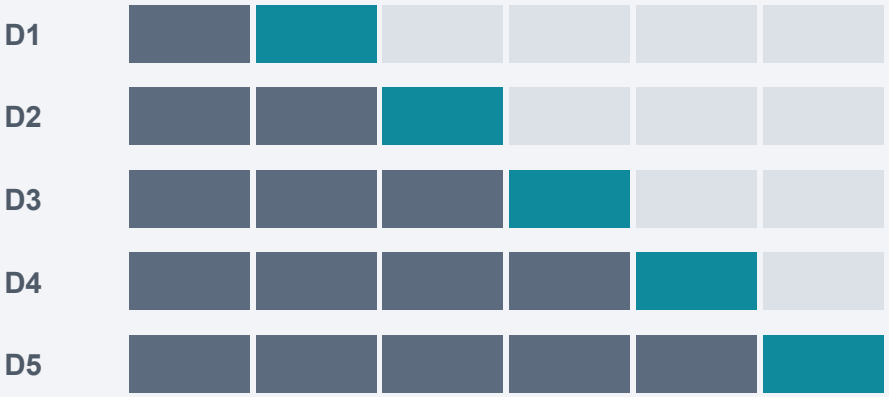


horas embaralhadas do ano inteiro

Treina com dias vizinhos ao teste: vê o “futuro”

Time Series Split

5 dobras em ordem cronológica



linha do tempo: jan → dez de 2025

Só aprende com o passado: desempenho real

Treino Teste (K-Fold) Teste (cronológico)

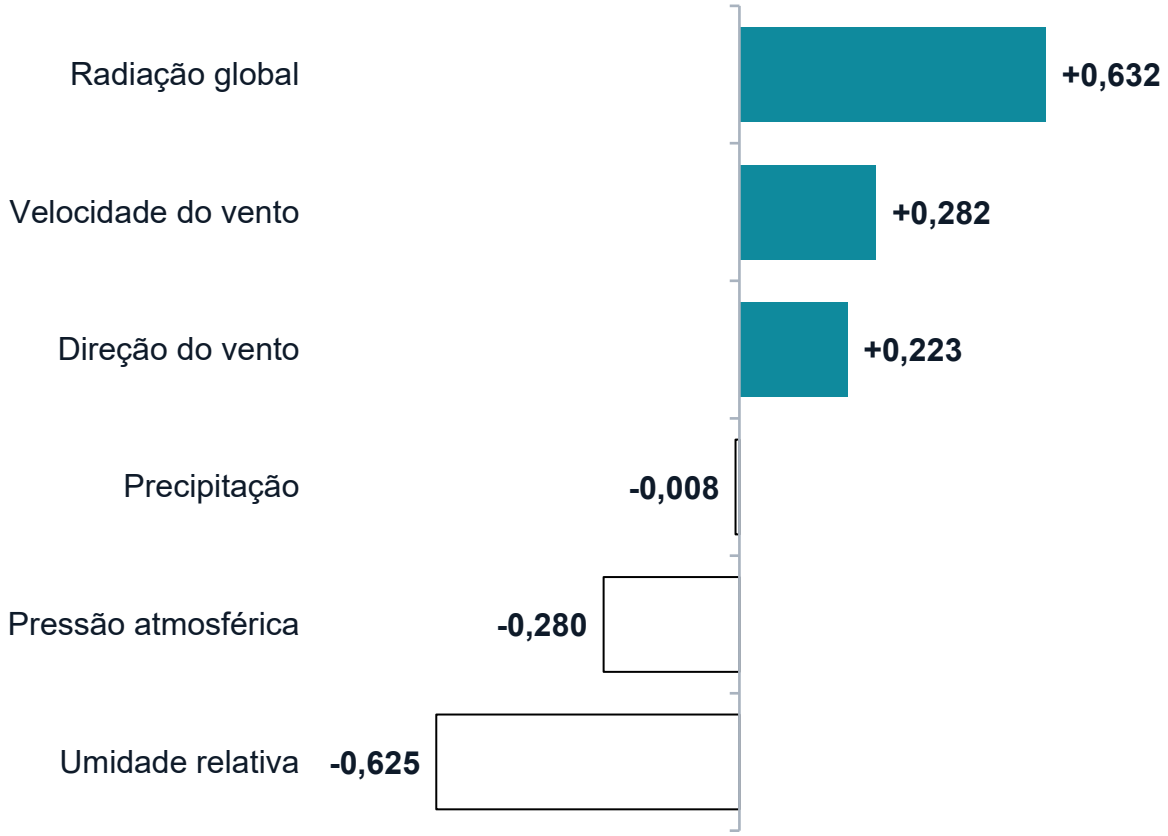
Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

RESULTADOS E DISCUSSÃO

PCA: o ciclo diurno aparece nos dados

Cargas do PC1 — Barueri, Cenário 1



+0,632
radiação global

−0,625
umidade relativa

Sol sobe, umidade cai: oposição quase simétrica no principal eixo de variação.

C2: as 3 umidades formam um “super-bloco” colinear

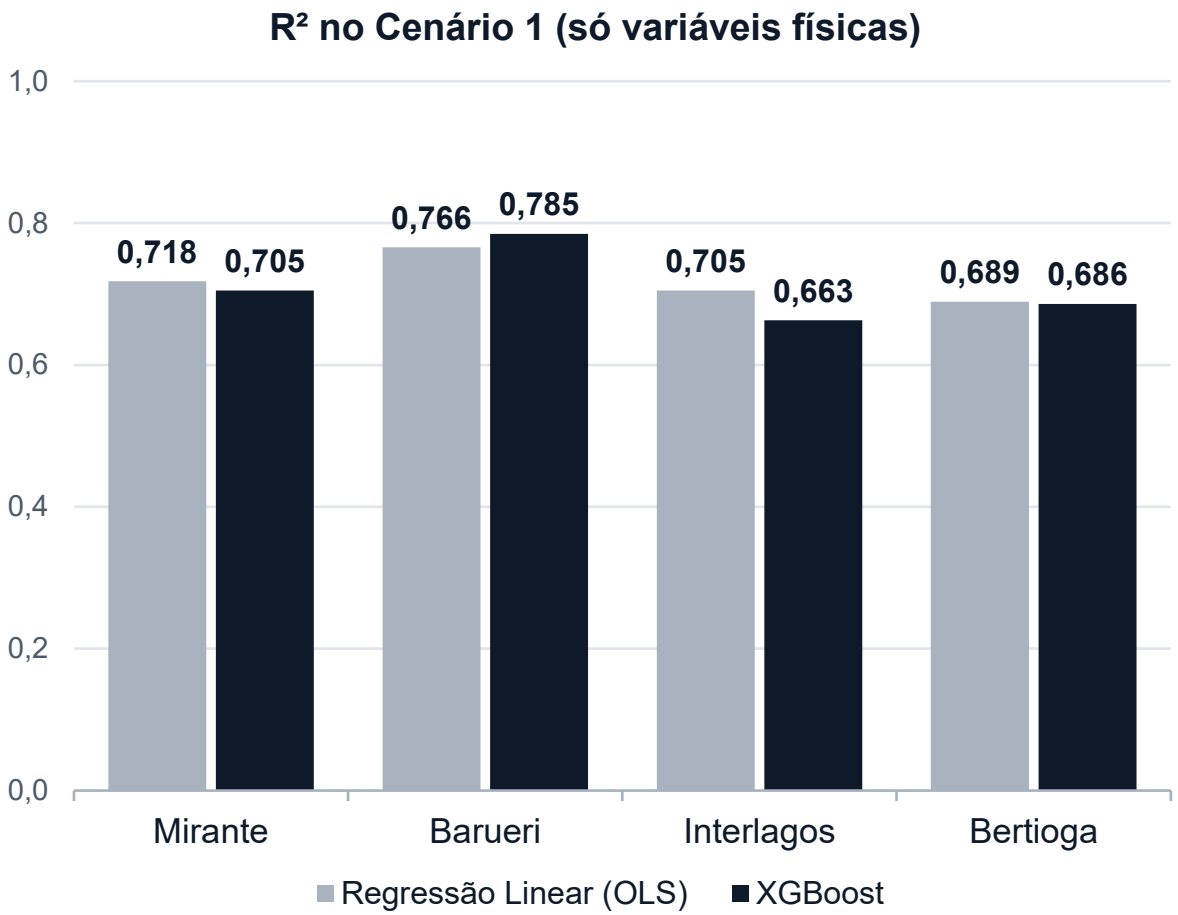
C3/C4: a Hora se alinha ao eixo da radiação

Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

RESULTADOS E DISCUSSÃO

Regressão linear acerta, mas não explica



Condition Number do OLS

até $5{,}61 \times 10^5$

mínimo de $2{,}56 \times 10^5$: multicolinearidade severa em todas as estações e cenários

Coeficientes instáveis: sem leitura física das variáveis

Árvores fazem divisões (splits): não sofrem com multicolinearidade

Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

RESULTADOS E DISCUSSÃO

Desempenho do XGBoost nos 4 cenários (R^2)

Estação	C1	C2	C3	C4
Mirante	0,705	0,712	0,766	**0,776**
Interlagos	0,663	0,677	**0,766**	0,765
Barueri	0,785	**0,795**	0,773	0,777
Bertioga	0,686	0,727	0,724	**0,744**

R^2 em dados futuros · em negrito, o melhor cenário de cada estação

0,795
melhor resultado
Barueri, Cenário 2 (continental)

3 de 4
estações melhoram
com Hora e Mês (C3/C4)

0,686
litoral é o mais difícil
Bertioga, Cenário 1

Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

RESULTADOS E DISCUSSÃO

O modelo se adapta à geografia de cada estação

Mirante de Santana

Cenário 4

19,8%

Mês do ano

o calendário calibra a ilha de calor

Barueri

Cenário 2

26,1%

Umidade mín. da hora anterior

inércia das massas de ar

Interlagos

Cenário 4

29,6%

Umidade mín. da hora anterior

saturação hídrica da represa

Bertioga

Cenário 1

41,4%

Pressão atmosférica

sinaliza a chegada de frentes frias

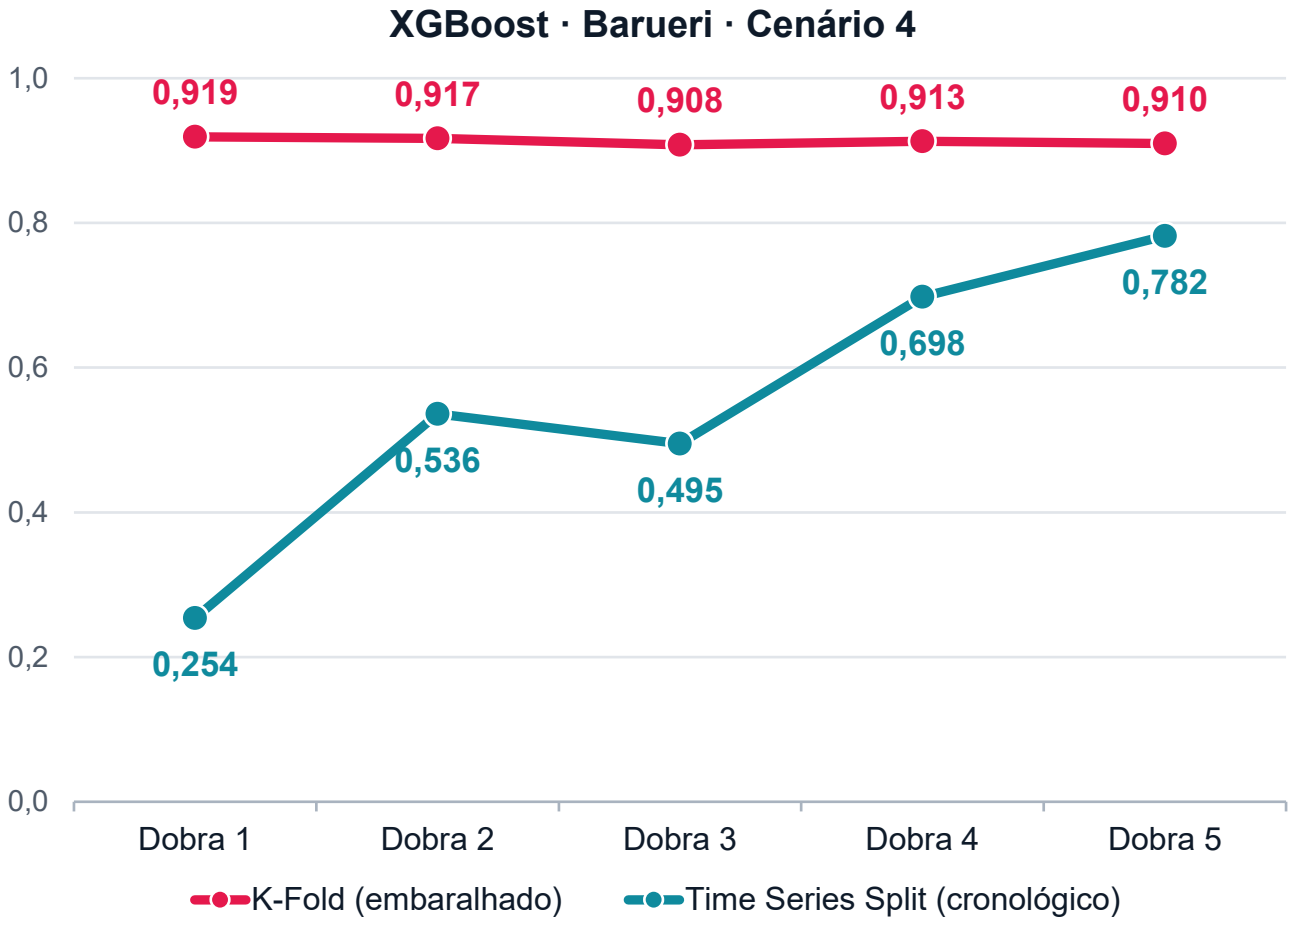
Importância das variáveis no XGBoost otimizado

Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

RESULTADOS E DISCUSSÃO

Principal achado: o K-Fold infla o R^2



0,913

R^2 médio no K-Fold
ilusão: memoriza o calendário
(Interlagos: 0,905)

0,254

Dobra 1: estação nunca vista
em Interlagos, cai para 0,089

0,782

Dobra 5: 7.300 h de treino
o desempenho real se recupera

Universidade Presbiteriana Mackenzie

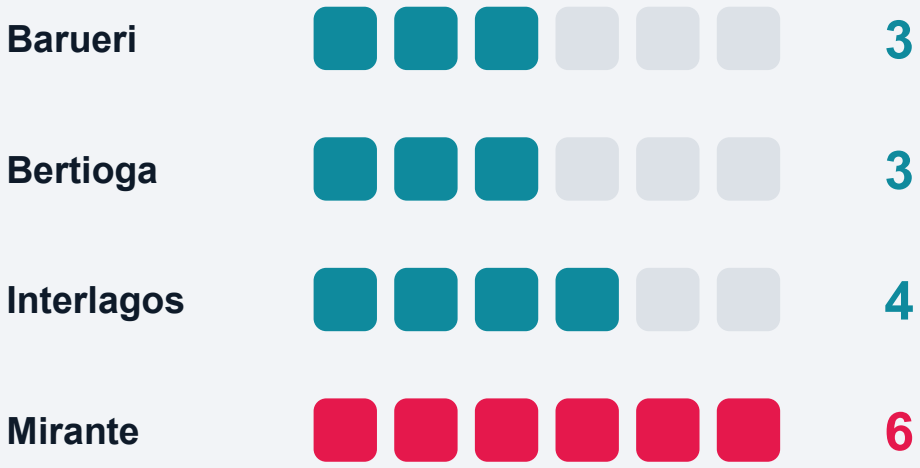
Iniciação Científica & Tecnológica

RESULTADOS E DISCUSSÃO

Árvores rasas e erro abaixo de 2 °C

Profundidade ideal das árvores

XGBoost otimizado · Cenário 4



300 treinamentos por cenário. Árvores rasas ignoram o ruído dos sensores; só a ilha de calor do Mirante pediu mais profundidade.

Bertioga · litoral

1,40 °C

MAE do XGBoost no Cenário 4

Barueri · continental

1,94 °C

MAE do Random Forest no Cenário 4

Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

CONSIDERAÇÕES FINAIS

O que este trabalho mostra

Arquiteturas rasas de árvores
Imunes à multicolinearidade e resistentes ao ruído dos sensores

Validação cronológica é obrigatória
K-Fold gera R^2 acima de 0,90; no cronológico, estabiliza entre 0,65 e 0,78

Cada microclima tem sua âncora
Umidade em Interlagos, calendário no Mirante, pressão em Bertioga

Próximos passos

Redes com memória sequencial
RNN e LSTM

Dados macrossinóticos
temperatura da superfície do mar e imagens de satélite

Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

REFERÊNCIAS

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5-32, 2001.

CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. In: **ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING**, 22., 2016, São Francisco. Proceedings... Nova York: ACM, 2016. p. 785-794.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The elements of statistical learning**: data mining, inference, and prediction. 2. ed. Nova York: Springer, 2009.

HYNDMAN, R. J.; ATHANASOPOULOS, G. **Forecasting**: principles and practice. 2. ed. Melbourne: OTexts, 2018. Disponível em: https://otexts.com/fpp2/. Acesso em: 21 jul. 2026.

JOLLIFFE, I. T.; CADIMA, J. Principal component analysis: a review and recent developments. **Philosophical Transactions of the Royal Society A**, v. 374, n. 2065, 2016.

KAUFMAN, S. et al. Leakage in data mining: formulation, detection, and avoidance. **ACM Transactions on Knowledge Discovery from Data**, v. 6, n. 4, art. 15, dez. 2012.

ROBERTS, D. R. et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. **Ecography**, v. 40, n. 8, p. 913-929, 2017.

Universidade Presbiteriana Mackenzie

AGRADECIMENTOS

Prof. Júlio Cesar Ardito · orientação

PIVIC Mackenzie · Programa Institucional Voluntário de Iniciação Científica

Obrigado! Perguntas?

Universidade Presbiteriana Mackenzie

daniel.valentim@mackenzista.com.br · julio.ardito@mackenzie.br