PREDIÇÃO DE PARÂMETROS CLIMÁTICOS COMO TEMPERATURA POR MEIO DO USO DE APRENDIZADO DE MÁQUINA

Daniel Borges Valentim (IC) e Júlio Cesar Ardito (Orientador)

Apoio:PIVIC Mackenzie

RESUMO

Este estudo avalia o desempenho de algoritmos de aprendizado de máquina na predição da temperatura horária em quatro microclimas distintos de São Paulo: capital, interior, represa e litoral. A modelagem climática enfrenta desafios possivelmente associados à alta não-linearidade e multicolinearidade das variáveis atmosféricas, o que invalida abordagens estatísticas tradicionais. Utilizando dados reais do Instituto Nacional de Meteorologia (INMET) de 2025, a metodologia comparou os modelos Regressão Linear, Random Forest, Gradient Boosting e XGBoost em quatro cenários incrementais de engenharia de atributos, englobando física limpa, defasagens históricas e marcadores temporais. A Análise de Componentes Principais (PCA) foi aplicada para mapear a estrutura vetorial do clima, comprovando o ciclo diurno e a formação de blocos colineares. Os resultados demonstraram que o modelo de regressão linear (OLS), embora competitivo em acurácia, apresentou coeficientes inutilizáveis devido à multicolinearidade severa. Por sua vez, o XGBoost entregou desempenho superior sem essa fragilidade interpretativa e obteve o melhor poder preditivo generalista, alcançando um coeficiente de determinação (R^2) de até 0,79 em cenários continentais. A descoberta central da pesquisa reside no diagnóstico do vazamento de dados sazonal (Data Leakage): a validação cruzada tradicional (K-Fold) gerou métricas ilusórias superiores a 0,90 ao memorizar variáveis de calendário. Em contrapartida, a simulação cronológica estrita (Time Series Split) revelou a incapacidade inicial dos algoritmos de extrapolar estações não vistas, mitigando o sobreajuste e estabilizando a performance real entre 0,65 e 0,78. Conclui-se que algoritmos de árvores são altamente eficazes na meteorologia, exigindo obrigatoriamente rigorosas validações temporais.

Palavras-chave: Predição climática. Aprendizado de máquina. Validação cruzada.

ABSTRACT

This study evaluates the performance of machine learning algorithms in predicting hourly temperature across four distinct microclimates in São Paulo: capital, inland, reservoir, and coast. Climate modeling faces challenges possibly associated with the high non-linearity and multicollinearity of atmospheric variables, which invalidates traditional statistical approaches. Using real 2025 data from the National Institute of Meteorology (INMET), the methodology compared Linear Regression, Random Forest, Gradient Boosting, and XGBoost models across four incremental feature engineering scenarios, encompassing pure physics, historical

lags, and temporal markers. Principal Component Analysis (PCA) was applied to map the climate's vector structure, proving the diurnal cycle and the formation of collinear blocks. Results demonstrated that the linear regression model (OLS), although competitive in accuracy, yielded unusable coefficients due to severe multicollinearity. Meanwhile, XGBoost delivered superior performance without this interpretive fragility and achieved the best general predictive power, reaching a coefficient of determination (R^2) of up to 0.79 in continental scenarios. The research's central discovery lies in the diagnosis of seasonal data leakage: traditional cross-validation (K-Fold) generated illusory metrics above 0.90 by memorizing calendar variables. Conversely, strict chronological simulation (Time Series Split) revealed the algorithms' initial inability to extrapolate unseen seasons, mitigating overfitting and stabilizing true performance between 0.65 and 0.78. It is concluded that tree-based algorithms are highly effective in meteorology, mandatorily requiring rigorous temporal validations.

Keywords: Climate prediction. Machine learning. Cross-validation.

1. INTRODUÇÃO

A previsão de parâmetros climáticos, como a temperatura do ar, é um desafio clássico e fundamental para a sociedade moderna, com impactos diretos na agricultura, na gestão de recursos hídricos, na prevenção de desastres naturais e no planejamento urbano. Tradicionalmente, a meteorologia tem se apoiado em Modelos de Previsão Numérica de Tempo (NWP - *Numerical Weather Prediction*), que utilizam equações da termodinâmica e da mecânica dos fluidos para simular a atmosfera. Contudo, a alta não-linearidade e o comportamento caótico dos sistemas climáticos em microescala muitas vezes limitam a precisão dessas abordagens numéricas em resoluções locais.

Diante desse cenário, a adoção de algoritmos de Aprendizado de Máquina (*Machine Learning*) desponta como uma alternativa robusta e eficiente. Diferente dos modelos físicos, os algoritmos orientados a dados são capazes de identificar padrões empíricos complexos em grandes volumes de registros históricos provenientes de estações meteorológicas de superfície. No entanto, a modelagem preditiva climática lida com variáveis altamente correlacionadas entre si — como radiação global, umidade relativa e pressão atmosférica —, o que frequentemente invalida abordagens estatísticas tradicionais baseadas em linearidade, exigindo o uso de algoritmos avançados baseados em árvores de decisão.

Um desafio metodológico central na aplicação de *Machine Learning* para séries temporais climáticas reside na correta incorporação e avaliação dos marcadores temporais, como a hora do dia e o mês do ano. A literatura aponta que a inclusão dessas variáveis é crucial para que os modelos capturem a dinâmica do ciclo diurno e da sazonalidade. Entretanto, a avaliação preditiva dessas arquiteturas é frequentemente conduzida de maneira equivocada na literatura acadêmica através da validação cruzada aleatória (*K-Fold*), o que permite ao algoritmo memorizar o calendário e acessar informações futuras, gerando métricas ilusórias de desempenho, fenômeno conhecido como vazamento de dados sazonal (*Seasonal Data Leakage*).

Portanto, este estudo tem como problema central a seguinte questão: como diferentes algoritmos de aprendizado de máquina se comportam ao prever a temperatura em microclimas distintos sob o efeito de variáveis históricas e temporais, e qual o real impacto do vazamento de dados em metodologias de validação? Para responder a essa indagação, a pesquisa utiliza dados horários do ano de 2025 do Instituto Nacional de Meteorologia (INMET) referentes a quatro estações localizadas no estado de São Paulo, cada qual com uma particularidade geográfica: Mirante de Santana (capital com efeito de ilha de calor), Barueri (região continental), Interlagos (proximidade a corpos d'água) e Bertioga (dinâmica costeira e brisa marítima).

O objetivo geral deste artigo é predizer a temperatura horária utilizando algoritmos de aprendizado de máquina e avaliar criticamente sua capacidade de generalização espacial e temporal. Como objetivos específicos, o trabalho busca: (I) mapear a estrutura vetorial das variáveis atmosféricas locais através da Análise de Componentes Principais (PCA); (II) comparar o desempenho de um modelo preditivo tradicional (Regressão Linear Múltipla) com modelos de *Ensembles* (*Random Forest*, *Gradient Boosting* e *XGBoost*); e (III) investigar a robustez metodológica dos modelos e o impacto do vazamento de dados temporal ao contrastar a validação cruzada tradicional (*K-Fold*) com a validação cronológica estrita (*Time Series Split*).

2. REFERENCIAL TEÓRICO

A modelagem de sistemas atmosféricos é caracterizada pela interação de variáveis físicas altamente correlacionáveis, como radiação solar, pressão atmosférica, velocidade do vento e umidade relativa do ar. A temperatura de superfície, em especial, responde não apenas às forçantes termodinâmicas instantâneas, mas também à inércia térmica do ambiente geográfico. Nesse contexto, a literatura científica demonstra que variáveis estritamente físicas muitas vezes são insuficientes para que modelos preditivos realizem previsões precisas sem um contexto exógeno de sazonalidade. Segundo Hyndman e Athanasopoulos (2018), na previsão de séries temporais, a inclusão de variáveis preditoras exógenas e marcadores de calendário (como a hora do dia e o mês do ano) atua como uma "âncora" sazonal, permitindo que os algoritmos estatísticos mapeiem o ciclo astronômico e capturem a latência natural de aquecimento e resfriamento que a pressão e radiação não representam de forma isolada.

Apesar da importância do cruzamento de variáveis físicas e temporais, o uso de modelos paramétricos tradicionais, como a Regressão Linear Múltipla baseada em Mínimos Quadrados Ordinários (OLS), encontra severas restrições. O modelo OLS pressupõe a ausência de multicolinearidade perfeita entre as variáveis independentes (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Contudo, na dinâmica climática, a radiação afeta a umidade que, por sua vez, interage com as massas de ar, gerando alta correlação. Essa colinearidade inflaciona a variância dos coeficientes (aumentando o *Condition Number*), tornando o modelo instável e incapaz de separar os efeitos individuais de cada atributo.

Para contornar as limitações de alta dimensionalidade e colinearidade, a Análise de Componentes Principais (PCA) é frequentemente utilizada. O PCA projeta os dados originais em novos eixos ortogonais (não correlacionados), ranqueados pela quantidade de variância que explicam no conjunto de dados (JOLLIFFE; CADIMA, 2016). Na meteorologia, o PCA auxilia na identificação da estrutura latente dos dados, comprovando a formação de blocos

físicos operantes (como a relação inversamente proporcional entre radiação e umidade ao longo do ciclo diurno).

Como solução preditiva para a não-linearidade do clima, consolidou-se a adoção de algoritmos de *Machine Learning* baseados em árvores de decisão e arquiteturas de *Ensembles*. O *Random Forest* utiliza a técnica de *Bagging*, criando múltiplas árvores independentes em subconjuntos aleatórios de dados e agregando seus resultados para reduzir a variância (BREIMAN, 2001). Simultaneamente, métodos de *Boosting*, como o *Extreme Gradient Boosting* (*XGBoost*), constroem árvores de forma sequencial para corrigir iterativamente os erros da etapa anterior (CHEN; GUESTRIN, 2016). O XGBoost se destaca em dados ruidosos (como leituras de sensores) por introduzir parâmetros nativos de regularização L1 e L2 que penalizam a complexidade estrutural das árvores, mitigando o sobreajuste (*overfitting*).

Por fim, a validação de algoritmos em séries temporais climáticas exige rigor metodológico para evitar métricas ilusórias. Kaufman et al. (2012) definem o fenômeno de Vazamento de Dados (*Data Leakage*) como a introdução inadvertida de informações externas ou futuras no treinamento do modelo, gerando resultados otimistas que não refletem a realidade de produção. Na validação tradicional (*K-Fold*), os dados são particionados aleatoriamente, ignorando a ordem do tempo. Conforme alertam Roberts et al. (2017) sobre a validação de modelos com dependência temporal, o embaralhamento de amostras quebra a estrutura cronológica e causa *overfitting*. Assim, ao utilizar variáveis indicadoras de calendário sob a abordagem *K-Fold*, cria-se o risco de o algoritmo memorizar as datas em vez de generalizar a física atmosférica, sendo mandatório o uso de estratégias de validação estritamente cronológicas, como o particionamento em janela deslizante (*Time Series Split*), para testar a real capacidade preditiva sazonal do modelo.

3. METODOLOGIA

A presente pesquisa caracteriza-se como um estudo empírico e quantitativo, de natureza explicativa e preditiva. O foco analítico consistiu em avaliar o desempenho de algoritmos de aprendizado de máquina na previsão da variável alvo "Temperatura do Ar - Bulbo Seco Horária (°C)". Para garantir a robustez e a generalização dos achados em diferentes perfis geográficos, foram selecionadas quatro estações meteorológicas automáticas de superfície operadas pelo Instituto Nacional de Meteorologia (INMET), localizadas no estado de São Paulo: Mirante de Santana (área densamente urbanizada com efeito de ilha de calor), Barueri (região metropolitana continental), Interlagos (área sob influência hídrica da represa Guarapiranga) e Bertioga (região litorânea sob constante

influência da brisa marítima). O recorte temporal da amostra compreendeu os registros horários coletados durante o ano de 2025.

A etapa de pré-processamento dos dados foi conduzida para assegurar a integridade da modelagem estatística. Os dados brutos passaram por conversões de tipagem e tratamento de valores ausentes (*Missing Values*). Para variáveis contínuas que apresentam progressão linear ao longo do dia, como radiação global e precipitação, aplicou-se a técnica de interpolação matemática bidirecional. Para as variáveis categóricas ou de alta volatilidade, como a direção e a velocidade do vento, as lacunas foram preenchidas utilizando a mediana da distribuição, mitigando o impacto de falhas instrumentais comuns em sensores expostos a intempéries.

O delineamento experimental foi estruturado em quatro cenários incrementais de engenharia de atributos (*Feature Engineering*), permitindo isolar o impacto de cada grupo de variáveis no poder preditivo dos modelos:

- Cenário 1 (Física Limpa): Utilização de 6 variáveis termodinâmicas estritamente instantâneas (precipitação total, pressão atmosférica, radiação global, umidade relativa do ar, direção e velocidade do vento).
- Cenário 2 (Física + Histórico): Expansão para 11 variáveis, incorporando o comportamento defasado da hora imediatamente anterior (pressão atmosférica máxima e mínima, umidade relativa máxima e mínima, e rajada máxima de vento).
- Cenário 3 (Física Limpa + Marcadores Temporais): Retorno às 6 variáveis do Cenário 1, acrescidas de duas variáveis exógenas de calendário (Hora do dia e Mês do ano), totalizando 8 atributos.
- Cenário 4 (Caos Total): Integração de todas as 13 variáveis disponíveis (físicas, históricas e temporais), submetendo os algoritmos ao cenário de máxima dimensionalidade e complexidade.

A análise estatística foi dividida em duas abordagens. Primeiramente, aplicou-se a Análise de Componentes Principais (PCA) como método não supervisionado para investigar a estrutura vetorial latente e comprovar a multicolinearidade das variáveis ambientais em cada localidade. Em seguida, a etapa de predição supervisionada contrastou um modelo paramétrico de referência, a Regressão Linear Múltipla (OLS), com três algoritmos de *Ensembles* baseados em árvores de decisão: *Random Forest* (*Bagging*), *Gradient Boosting* e *eXtreme Gradient Boosting* (*XGBoost*).

Para otimização das arquiteturas, aplicou-se a técnica de *Fine-Tuning* com 300 interações de treinamento por cenário para localizar os melhores hiperparâmetros (como taxa

de aprendizado, profundidade máxima das árvores e subamostragem de colunas). O desempenho preditivo foi mensurado através do Coeficiente de Determinação (R^2), Erro Médio Absoluto (MAE) e Raiz do Erro Quadrático Médio (RMSE).

Por fim, a estratégia de avaliação metodológica visou diagnosticar ativamente a ocorrência de Vazamento de Dados Sazonal (*Data Leakage*). Para tanto, o melhor modelo ajustado foi submetido a duas rotinas distintas de validação cruzada com 5 dobras (*5-splits*): o método tradicional *K-Fold*, que realiza o embaralhamento aleatório dos dados (*Shuffle*), quebrando a linearidade do tempo; e o método *Time Series Split*, que bloqueia o acesso a dados futuros, realizando o treinamento em janelas deslizantes estritamente cronológicas. A discrepância de performance entre essas duas estratégias serviu como base empírica para validar ou refutar a capacidade real de extrapolação dos algoritmos frente às mudanças de estações do ano.

4. RESULTADO E DISCUSSÃO

4.1. Avaliação do Modelo Linear e o Impacto da Multicolinearidade

A primeira etapa experimental consistiu na aplicação do modelo paramétrico de Regressão Linear Múltipla (OLS) para estabelecer uma linha de base preditiva nos quatro microclimas avaliados. Conforme ilustrado no Gráfico 1, o modelo OLS demonstrou-se competitivo em termos de acurácia inicial, superando marginalmente o XGBoost em três das quatro localidades no Cenário 1 (variáveis puramente físicas), com Coeficientes de Determinação (R^2) variando de 0,689 em Bertioga a 0,766 em Barueri.

Contudo, a análise estrutural da regressão revelou uma limitação crítica na aplicação dessa técnica à dinâmica atmosférica. Em todas as localidades e cenários testados, o modelo OLS emitiu um severo alerta de multicolinearidade estatística. Esse fato foi evidenciado pela explosão do Condition Number, métrica de diagnóstico que registrou valores na ordem de 3.46 x 10^5 no Mirante de Santana (Cenário 1) e alcançou até 5.61 x 10^5 no Cenário 4 de Interlagos. Na estatística, a multicolinearidade não destrói a capacidade preditiva geral do modelo, mas arruína completamente a interpretação de seus coeficientes. A forte interdependência entre variáveis como radiação e umidade inflaciona a variância dos pesos calculados, tornando a equação linear resultante inutilizável para a leitura física das forçantes climáticas.

Diante dessa fragilidade interpretativa, as arquiteturas não lineares baseadas em árvores de decisão (Ensembles) confirmaram-se como a abordagem metodológica superior. Conforme sumarizado na Tabela 1, a introdução de variáveis temporais nos Cenários 3 e 4 eleva o R^2 aparente do modelo OLS. No entanto, esse desempenho na regressão linear é estatisticamente inválido, pois é atrelado à extrema multicolinearidade temporal (com

Condition Number superior a 4.0 x 10^5). Nesse cenário de interações complexas, modelos como o Random Forest e o XGBoost destacam-se como a única alternativa viável: eles entregam um desempenho preditivo robusto (alcançando R² de 0,777 em Barueri no C4), lidando nativamente com a não-linearidade do calendário sem colapsar matematicamente.

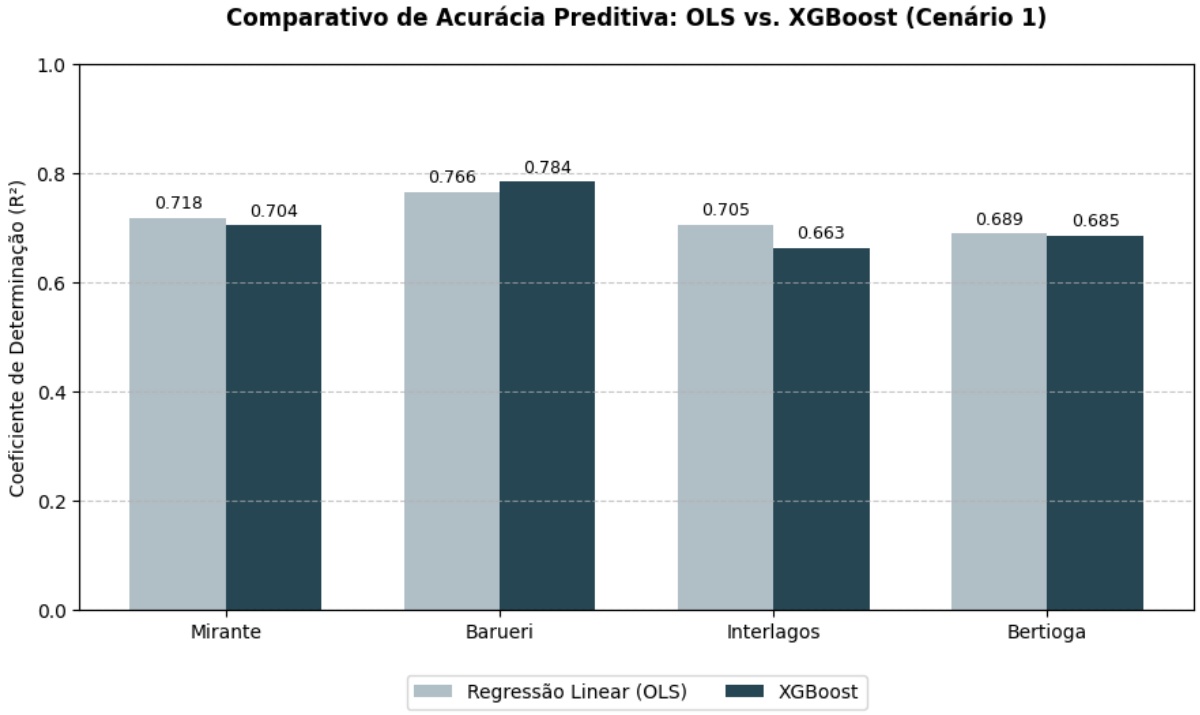
Tabela 1 - Comparativo do Coeficiente de Determinação (R²) entre os Algoritmos Avaliados

Localidade (Microclima)	Modelo	Cenário 1	Cenário 2	Cenário 3	Cenário 4
Mirante (Capital)	OLS	0,718	0,721	0,775	0,777
	Random Forest	0,703	0,717	0,747	0,751
	Gradient Boosting	0,714	0,720	0,774	0,777
	XGBoost	0,705	0,712	0,766	0,776
Interlagos (Represa)	OLS	0,705	0,709	0,770	0,773
	Random Forest	0,653	0,679	0,739	0,729
	Gradient Boosting	0,665	0,676	0,762	0,769
	XGBoost	0,663	0,677	0,766	0,765
Barueri (Continental)	OLS	0,766	0,772	0,786	0,791
	Random Forest	0,775	0,778	0,758	0,757
	Gradient Boosting	0,773	0,777	0,766	0,773
	XGBoost	0,785	0,795	0,773	0,777
Bertioga (Litoral)	OLS	0,689	0,700	0,755	0,758
	Random Forest	0,672	0,704	0,707	0,730

Localidade (Microclima)	Modelo	Cenário 1	Cenário 2	Cenário 3	Cenário 4
	Gradient Boosting	0,723	0,733	0,714	0,724
	XGBoost	0,686	0,727	0,724	0,744

Fonte: O próprio autor.

Gráfico 1 - Comparativo de R² entre OLS e XGBoost no Cenário 1



Fonte: O próprio autor.

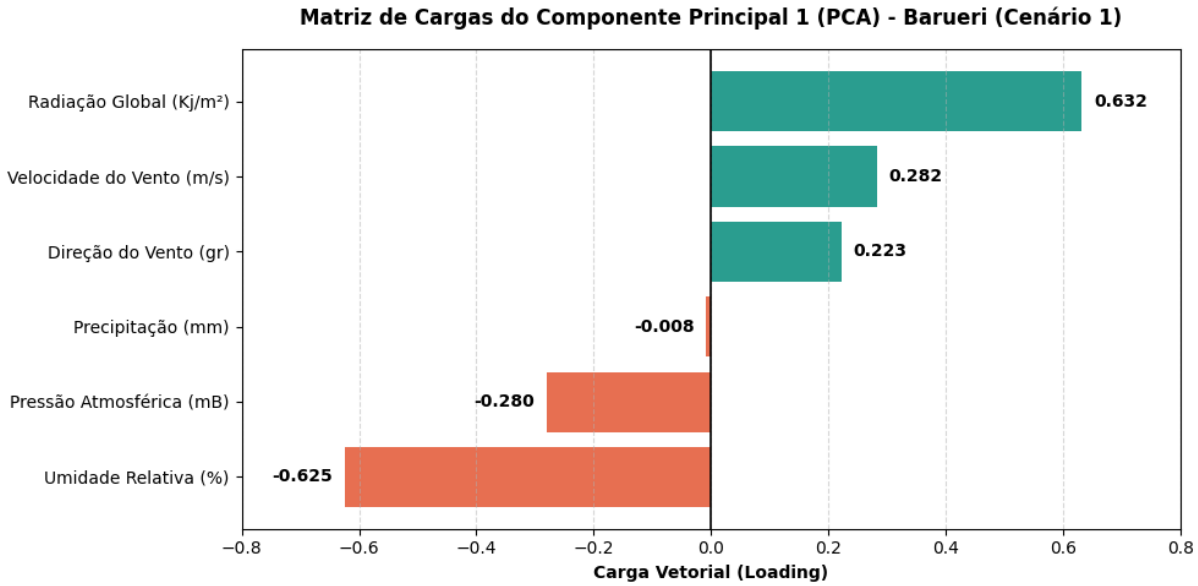
4.2. Estrutura Latente do Clima e a Prova do Ciclo Diurno (PCA)

Para investigar a estrutura de correlação entre os atributos meteorológicos, aplicou-se a Análise de Componentes Principais (PCA) em todas as localidades. O comportamento vetorial do Componente Principal 1 (PC1), que condensa a maior parcela da variância dos dados, revelou um padrão físico universal operando sobre o estado de São Paulo.

No Cenário 1 (variáveis instantâneas), o PC1 capturou majoritariamente o "Ciclo Diurno/Radiativo". Em Mirante de Santana e Barueri, a Radiação Global apresentou cargas de forte magnitude (0,592 e 0,632, respectivamente), operando em oposição vetorial exata à Umidade Relativa do Ar (-0,590 e -0,625). Essa oposição matemática traduz perfeitamente o fenômeno térmico diário: à medida que o sol eleva a radiação, a umidade despenca de forma simétrica.

Quando o Cenário 2 expandiu a dimensionalidade introduzindo o histórico da hora anterior, o algoritmo PCA formou um "Super-Bloco de Saturação". O PC1 passou a ser liderado pela atuação conjunta e positiva da Umidade Relativa Instantânea, Umidade Mínima Anterior e Umidade Máxima Anterior, que assumiram as três maiores cargas estruturais simultaneamente em Interlagos (todas acima de 0,435) e Barueri (acima de 0,406). Ao avançar para os Cenários 3 e 4, a introdução das variáveis temporais comprovou que a Hora atrela-se nativamente ao vetor de radiação e ventos térmicos, demonstrando que os marcadores de calendário funcionam como moduladores matemáticos das forças termodinâmicas.

Gráfico 2 - Matriz de Cargas do PC1 para o Cenário 1 (Barueri)



Fonte: O próprio autor.

4.3. Dinâmica das Variáveis e a Adaptação Geográfica

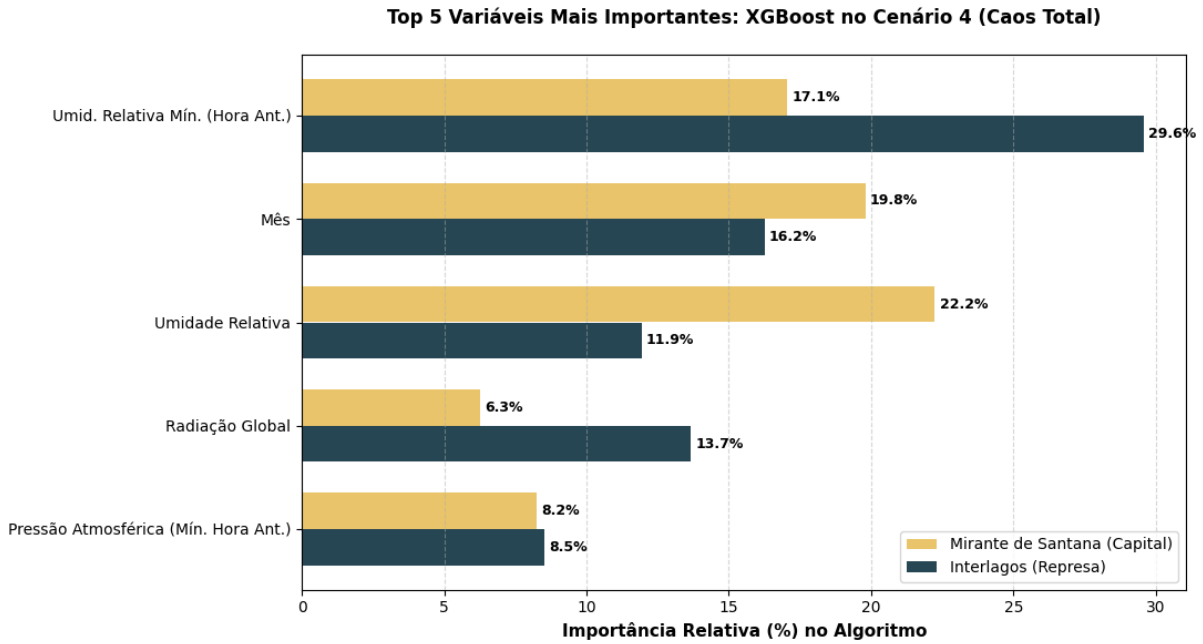
A avaliação da Importância das Variáveis (*Feature Importance*) nos algoritmos de *Ensembles*, com destaque para o XGBoost, evidenciou a notável capacidade do aprendizado de máquina em adaptar suas regras de predição às características geográficas de cada microclima. O algoritmo não utilizou uma "receita única"; em vez disso, alterou o peso de suas raízes de decisão conforme a localidade avaliada.

Em Barueri, caracterizada por um clima continental metropolitano estável, o modelo apoiou-se fortemente nas transições de ciclo. No Cenário 2 (física e histórico), a Umidade Relativa Mínima da Hora Anterior assumiu o topo da relevância preditiva (26,07%), seguida pela Umidade Relativa instantânea (20,44%). O algoritmo inferiu que a temperatura no interior metropolitano é estritamente guiada pela inércia das massas de ar da hora passada. A geografia da estação de Interlagos, localizada em proximidade à represa Guarapiranga, induziu um comportamento focado na saturação da água. No Cenário 4, a Umidade Mínima

da Hora Anterior manteve o domínio absoluto do modelo XGBoost, pesando 29,59%, demonstrando que a proximidade com o bolsão d'água torna a névoa da hora anterior o preditor mais vital.

Em contrapartida, o Mirante de Santana expôs o efeito da "Ilha de Calor" urbana. A absorção de calor pelo concreto durante o dia e a liberação durante a noite rompem a linearidade térmica natural. Para lidar com essa anomalia macroclimática no Cenário 4, o XGBoost ancorou-se expressivamente na variável Mês (19,80%), indicando que o algoritmo precisa do contexto sazonal do calendário para calibrar a temperatura das madrugadas da capital. Por fim, a estação de Bertioga representou o cenário de maior caos ambiental. Assolado pela instabilidade da brisa marítima, o XGBoost no Cenário 1 focou na forçante termodinâmica mais ampla: a Pressão ao Nível da Estação (41,44%). O modelo aprendeu que, no litoral, o "delta" de pressão (avanço de frentes frias) é o preditor mais seguro contra a volatilidade dos demais sensores.

Gráfico 3 - Importância preditiva das variáveis em microclimas distintos



Fonte: O próprio autor.

4.4. O Choque Sazonal e o Diagnóstico de Vazamento de Dados

Avançando na avaliação metodológica dos modelos, a pesquisa submeteu as arquiteturas a testes de estresse para diagnosticar a ocorrência de Vazamento de Dados Sazonal (*Data Leakage*), um erro frequentemente negligenciado na literatura aplicada. Diversos estudos contemporâneos que utilizam *Machine Learning* para previsão meteorológica relatam coeficientes de determinação (R^2) superiores a 0,90 ao incluir variáveis de calendário em validações cruzadas tradicionais (*K-Fold*). Os resultados desta pesquisa replicaram empiricamente essa métrica otimista: ao avaliar o algoritmo XGBoost no Cenário

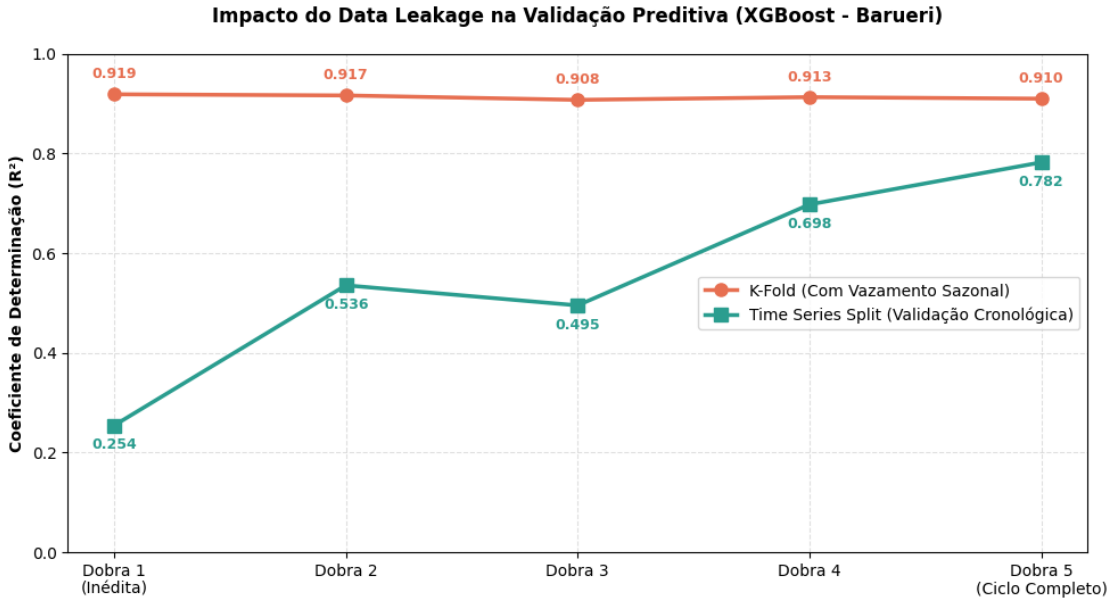
4 (física e tempo) utilizando o *K-Fold* de 5 dobras, o modelo alcançou um R^2 médio de 0,913 em Barueri e 0,905 em Interlagos.

Contudo, ao adotar as diretrizes de validação cronológica estrita – isto é, preservando a ordenação natural dos registros e bloqueando sumariamente o acesso a dados futuros durante o treinamento -, a pesquisa diagnosticou que essas métricas próximas à perfeição são ilusórias. O método *K-Fold*, ao embaralhar aleatoriamente os registros do ano de 2025, permitiu que o algoritmo fragmentasse o tempo, treinando com dias do inverno para prever dados isolados do verão. Nesse ambiente de vazamento de informações futuras, a árvore de decisão não aprende a transição termodinâmica; ela atua como um motor de busca, utilizando as variáveis indicadoras Mês e Hora apenas para localizar a resposta preditiva no calendário memorizado.

Para expor o real poder de generalização do algoritmo, o mesmo XGBoost otimizado foi submetido ao método *Time Series Split* (janela deslizante progressiva), que bloqueia o acesso a dados futuros. O choque sazonal revelou-se imediato: na Dobra Temporal 1 de Barueri (treino em 1460 horas e teste nas 1460 horas subsequentes), forçando o modelo a prever uma nova estação do ano que ele jamais havia "vivido", o R^2 colapsou de 0,913 para apenas 0,254. Na estação de Interlagos, o cenário foi ainda mais drástico, despencando para 0,089 na primeira dobra temporal.

A estabilidade matemática só foi restaurada conforme a janela de treinamento deslizou e acumulou o histórico de múltiplas estações. Na Dobra Temporal 5, tendo assimilado a dinâmica anual completa (7300 horas de treino disponíveis), o XGBoost recuperou seu poder preditivo, estabilizando sua precisão real em 0,782 para Barueri e 0,741 para Interlagos. Essa descoberta comprova que a validação puramente cronológica é uma obrigatoriedade estatística na modelagem meteorológica.

Gráfico 4 - Impacto do Data Leakage na Validação Preditiva (Barueri)



Fonte: O próprio autor.

4.5. O Paradoxo do Fine-Tuning e a Arquitetura das Árvores

Tendo estabelecido a métrica real e livre de vazamentos, a pesquisa procedeu à etapa de otimização de hiperparâmetros (*Fine-Tuning*). O objetivo foi adequar a estrutura interna dos algoritmos à complexidade de cada microclima. O algoritmo XGBoost foi submetido a uma busca em grade com validação cruzada (*GridSearchCV*), totalizando 300 treinamentos por cenário, para testar combinações de profundidade da árvore (max_depth), taxa de aprendizado (learning_rate) e subamostragem (subsample).

A Tabela 1 apresenta as melhores arquiteturas encontradas para o Cenário 4 (Caos Total) nas quatro estações. Um padrão notável e contraintuitivo emergiu do processo de otimização: apesar de o Cenário 4 oferecer 13 variáveis distintas, o algoritmo penalizou estruturas complexas e priorizou árvores rasas. Em Barueri e Bertioga, a profundidade máxima ideal estagnou em apenas 3 nós de decisão (max_depth = 3). Em Interlagos, atingiu a profundidade de 4. Apenas no Mirante de Santana o algoritmo exigiu maior complexidade, chegando a 6 níveis de profundidade.

Essa preferência estrutural por árvores menores reflete a ação dos hiperparâmetros de regularização nativos do XGBoost lidando com dados meteorológicos do mundo real. Os sensores do INMET estão sujeitos a intempéries que geram ruídos estatísticos severos, como oscilações bruscas na rajada máxima de vento ou falhas de precipitação instantânea. Se o algoritmo permitisse o crescimento ilimitado de suas folhas, ele inevitavelmente memorizaria esse ruído geográfico (*overfitting*). Ao manter a profundidade restrita a 3 ou 4 níveis, o *Fine-Tuning* forçou o modelo a ignorar a volatilidade sensorial e a tomar decisões baseadas exclusivamente nas grandes forçantes climáticas locais (Radiação, Umidade e Tempo).

Tabela 2 - Melhores hiperparâmetros do XGBoost encontrados no Cenário 4

Localidade (Microclima)	max_depth	n_estimators	learning _rate	subsample	colsample_bytree
Mirante de Santana (Capital)	6	300	0.01	0.6	0.6
Interlagos (Represa)	4	100	0.10	0.8	1.0
Barueri (Continental)	3	100	0.20	0.7	0.9
Bertioga (Litoral)	3	100	0.10	0.9	0.9

Fonte: O próprio autor.

4.6. Análise de Erros Absolutos na Climatologia

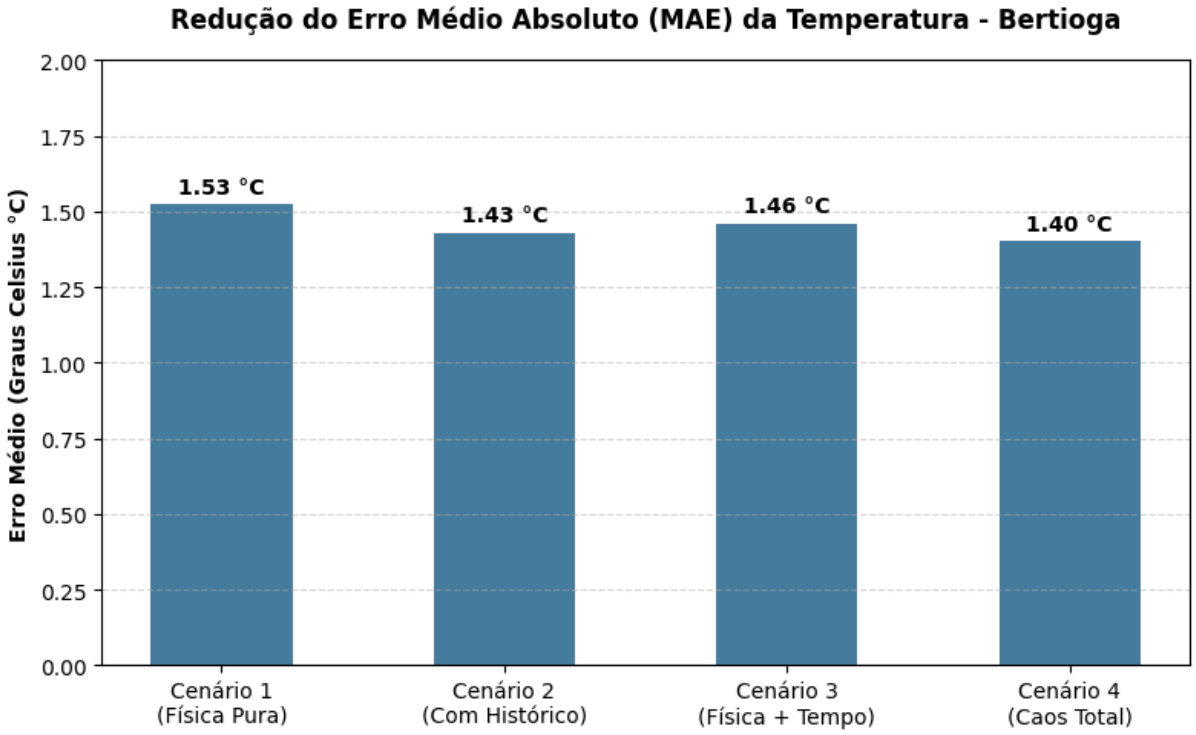
Embora o Coeficiente de Determinação (R^2) seja a métrica primária para avaliar a aderência do modelo à variância dos dados, a utilidade meteorológica de uma ferramenta preditiva depende de sua assertividade na escala física do mundo real, medida em graus Celsius (°C). Para isso, extraiu-se o Erro Médio Absoluto (MAE) e a Raiz do Erro Quadrático Médio (RMSE).

A estação litorânea de Bertioga, apesar de apresentar o R^2 mais conservador entre as localidades estudadas (devido ao microclima altamente caótico da brisa marítima), obteve uma precisão térmica excepcional. No Cenário 1 (variáveis puramente físicas sem otimização temporal), o XGBoost registrou um MAE de 1,52 °C e um RMSE de 1,94 °C. Quando submetido ao Cenário 4, com o *Fine-Tuning* calibrado para árvores rasas e a inclusão das âncoras temporais (Mês e Hora), o erro caiu significativamente. O XGBoost otimizado no Cenário 4 alcançou um MAE de apenas 1,40 °C e um RMSE de 1,75 °C.

Em metrópoles como Barueri, o desempenho físico manteve o padrão de excelência, com o *Random Forest* (Cenário 4) apresentando um MAE de 1,94 °C e um RMSE de 2,36 °C na predição horária. Essa ordem de magnitude — errar a temperatura em menos de 1,50 °C

no litoral e menos de 2,00 °C em áreas urbanas — comprova a robustez operacional dos algoritmos baseados em árvores. Os Ensembles não apenas superaram a fragilidade interpretativa da multicolinearidade presente nos modelos lineares, como produziram limites de erro estritamente aceitáveis para aplicações práticas em engenharia agrícola e planejamento civil, desde que o ambiente de treinamento respeite a validação cronológica das estações do ano.

Gráfico 5 - Evolução do Erro Médio Absoluto (MAE) em Bertioga



Fonte: O próprio autor.

5. CONSIDERAÇÕES FINAIS

A presente pesquisa propôs-se a investigar a viabilidade, a precisão e, sobretudo, a robustez metodológica da aplicação de algoritmos de aprendizado de máquina na previsão termodinâmica de microclimas. Através do monitoramento da variável "Temperatura do Ar - Bulbo Seco Horária" em quatro estações meteorológicas distintas do estado de São Paulo (Mirante de Santana, Interlagos, Barueri e Bertioga), o estudo não apenas validou o uso de inteligência artificial na climatologia, mas também expôs falhas críticas nas abordagens estatísticas tradicionais e nas metodologias de validação amplamente aceitas na literatura.

O primeiro marco conclusivo deste trabalho reside na reavaliação do uso de modelos paramétricos lineares no trato de variáveis ambientais instantâneas. A aplicação da Regressão Linear Múltipla (OLS) revelou que, embora o modelo seja competitivo em acurácia preditiva inicial, as forçantes físicas da atmosfera operam sob extrema multicolinearidade. A explosão do Condition Number em todos os cenários atestou matematicamente que a

radiação solar, a umidade relativa e a pressão atmosférica não podem ser tratadas como vetores independentes. Como consequência, a multicolinearidade destrói a interpretação física dos coeficientes do OLS, tornando-os inutilizáveis para a compreensão termodinâmica do clima. Diante dessa limitação, as arquiteturas não lineares baseadas em árvores de decisão — em especial o eXtreme Gradient Boosting (XGBoost) e o Random Forest — entregam desempenho equivalente ou superior sem essa fragilidade interpretativa, além de vencerem o modelo linear por larga margem ao acomodarem as complexas não-linearidades introduzidas nos cenários temporais avançados.

Ademais, a análise de Componentes Principais (PCA) e o estudo da importância das variáveis (*Feature Importance*) comprovaram que algoritmos de *Ensembles* não operam como caixas-pretas estáticas; eles mimetizam a física local. A pesquisa evidenciou que cada microclima exige uma âncora preditiva distinta: enquanto a estação de Interlagos demonstrou altíssima dependência da inércia de umidade da hora anterior devido à proximidade com a represa Guarapiranga, a estação do Mirante de Santana ancorou-se no calendário (Mês) para corrigir a não-linearidade térmica causada pela ilha de calor urbana da capital. Já no litoral de Bertioga, o algoritmo aprendeu a contornar o caos provocado pela brisa marítima apoiando-se prioritariamente nas variações de pressão atmosférica.

Apesar do notável desempenho preditivo, a principal contribuição científica deste artigo consiste no diagnóstico do Vazamento de Dados Sazonal (*Data Leakage*). O estudo provou empiricamente que a inclusão de variáveis exógenas de calendário (Hora e Mês) em rotinas de validação cruzada aleatória (*K-Fold*) gera métricas de desempenho otimistas e irreais, frequentemente superando a marca de 0,90 no Coeficiente de Determinação (R^2). A simulação cronológica estrita, conduzida através do *Time Series Split*, revelou que algoritmos de árvores de decisão entram em colapso preditivo ao tentar extrapolar comportamentos para estações do ano inéditas no conjunto de treinamento. Contudo, uma vez que o ciclo anual completo é assimilado, o modelo estabiliza-se e entrega previsões altamente confiáveis, culminando em um Erro Médio Absoluto (MAE) surpreendente, variando de apenas 1,40 °C no litoral a 1,94 °C nas áreas urbanas.

Conclui-se, portanto, que a otimização de modelos climáticos não passa pela criação de árvores profundas e complexas, mas sim pela adoção de arquiteturas rasas — que ignoram o ruído dos sensores — combinadas com uma validação cronológica inquebrável. Como sugestão para trabalhos futuros, recomenda-se a aplicação de arquiteturas de *Deep Learning* focadas em memória sequencial, como Redes Neurais Recorrentes (RNN) e *Long Short-Term Memory* (LSTM), para contrastar com os resultados baseados em árvores aqui obtidos. Adicionalmente, a expansão do banco de dados para incluir variáveis macrossinóticas, como

a temperatura da superfície do mar (TSM) e imagens de satélite, poderia fornecer o contexto climático antecipado que faltou às árvores de decisão durante a transição de novas estações.

6. REFERÊNCIAS

BREIMAN, L. Random forests. Machine Learning, v. 45, n. 1, p. 5-32, 2001.

CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22., 2016, São Francisco. Proceedings... Nova York: ACM, 2016. p. 785-794.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The elements of statistical learning: data mining, inference, and prediction. 2. ed. Nova York: Springer, 2009.

HYNDMAN, R. J.; ATHANASOPOULOS, G. Forecasting: principles and practice. 2. ed. Melbourne: OTexts, 2018. Disponível em: https://otexts.com/fpp2/. Acesso em: 21 jul. 2026.

JOLLIFFE, I. T.; CADIMA, J. Principal component analysis: a review and recent developments. Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences, v. 374, n. 2065, 2016.

KAUFMAN, S. et al. Leakage in data mining: formulation, detection, and avoidance. ACM Transactions on Knowledge Discovery from Data, v. 6, n. 4, art. 15, dez. 2012.

ROBERTS, D. R. et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. Ecography, v. 40, n. 8, p. 913-929, 2017.

Contatos: daniel.valentim@mackenzista.com.br e julio.ardito@mackenzie.br